

Порівняльний аналіз методів виділення універсальних ознак у моделях простору станів

Моделі простору станів, або State Space Models, далі SSM, істотно відрізняються від класичних згорткових мереж і трансформерів тим, що їхні внутрішні представлення формуються не через локальні згорткові фільтри або явні матриці уваги, а через латентну динаміку стану.

У лінійному випадку така модель задається рівняннями

$$x'(t) = Ax(t) + Bu(t), \quad y(t) = Cx(t) + Du(t),$$

де $u(t)$ є вхідним сигналом, $x(t)$ є латентним станом, а $y(t)$ є виходом моделі. Після дискретизації така система може розглядатися як рекурентна модель або як згортка з імпульсною характеристикою

$$K_k = CA^k B.$$

Саме ця подвійність створює головну відмінність SSM від CNN та ViT: ознаки доцільно шукати не лише у прихованих активаціях, а також у ядрах, модах, власних значеннях, полюсах, імпульсних характеристиках і, для selective SSM, у вхідно-залежних маршрутах передавання інформації.

1. Порівняння сімейств SSM

Різні сімейства SSM мають різну структуру латентної динаміки, тому природний рівень аналізу ознак для них також відрізняється. Для лінійних часово-інваріантних моделей основними об'єктами аналізу є ядра, моди та частотні характеристики, тоді як для selective SSM важливішими є вхідно-залежні патерни маршрутизації інформації.

Сімейство	Структурна основа	Кандидат на ознаку	Інтерпретаційний зміст	Основне обмеження
HiPPO та ранні SSM	Лінійна часово-інваріантна система, що апроксимує історію сигналу через ортогональні базисні проекції.	Коефіцієнт базисної проекції або згладжена історична компонента.	Часовий масштаб, тренд, довготривала пам'ять.	Коефіцієнти часто є абстрактними і не мають прямої семантичної інтерпретації.
S4	Структурована SSM з матрицею стану типу diagonal plus low-rank.	Ядро згортки, полюс, власна мода, полюсно-резидуальна пара.	Довготривала залежність, лаг, частотний фільтр.	Сирі координати стану не є стабільними семантичними одиницями.
DSS та S4D	Діагональна або спрощена діагональна параметризація SSM.	Окрема діагональна мода або частотна смуга.	Чистіший часовий або спектральний детектор.	Навіть діагональні моди можуть змішувати різні семантичні фактори.

Сімейство	Структурна основа	Кандидат на ознаку	на Інтерпретаційний зміст	Основне обмеження
S5	MIMO-SSM, тобто один багатовхідний і багатовихідний простір станів.	Спільна мода, що діє на кілька вхідних і вихідних каналів.	Міжканальний часовий мотив.	МІМО-змішування ускладнює відповідність між однією координатою і одним поняттям.
LRU	Діагональна лінійна рекурентна модель з нормалізованою динамікою.	Рекурентний канал або стабільна власна мода.	Довготривалий лічильник, структурна пам'ять, акумуляція історії.	Потрібне зіставлення каналів між різними запусками навчання.
Mamba	Selective SSM, у якій параметри динаміки залежать від поточного входу.	Вхідно-залежний маршрут, gate-патерн або dependency motif.	Контентне маршутизування, вибіркоче збереження або забування інформації.	Один і той самий канал може виконувати різні ролі в різних контекстах.
ViM	Візуальна модель на основі bidirectional Mamba blocks.	Просторова карта після обернення послідовності патчів у 2D-координати.	Границі, частини об'єкта, глобальна форма.	Порядок сканування може створювати артефакти.
VMamba	Візуальна SSM з 2D selective scan.	Маршрутно-залежна просторова ознака або dependency pattern.	Просторовий контекст, глобальна взаємодія областей зображення.	Потрібна перевірка ознак для різних напрямів сканування.

2. Критерії коректного виділення універсальної ознаки

Ознаку в SSM не можна вважати універсальною лише тому, що вона дає високу активацію або добре працює в одному запуску навчання. Коректна перевірка повинна враховувати семантичну узгодженість, стабільність між незалежно навченими моделями, каузальний вплив на результат, переносимість на інші задачі та, для selective SSM, сталість вхідно-залежних маршрутів.

Формально таку перевірку можна подати як набір критеріїв

$$\Phi = (A, S, C, T, D),$$

де A позначає узгодженість з інтерпретованим поняттям, S позначає стабільність між різними seed-моделями, C позначає каузальну важливість, T позначає переносимість на інші задачі, а D позначає стабільність залежностей для selective SSM.

Критерій	Зміст	Практична перевірка
A	Alignment: ознака має відповідати інтерпретованому поняттю.	IoU з масками понять, span-IoU для тексту або часових рядів, узгодження з частотними областями для аудіо.
S	Stability: ознака має повторюватися у незалежно навчених моделях.	Зіставлення каналів, мод або підпросторів між різними seed-моделями.
C	Causal importance: ознака повинна впливати на поведінку моделі.	Ablation, intervention, deletion AUC, падіння якості після вимкнення ознаки.
T	Transfer utility: ознака повинна бути корисною на іншій задачі.	Лінійний probe або простий класифікатор на заморожених ознаках.
D	Dependency consistency: для selective SSM має зберігатися подібний патерн залежностей.	Порівняння induced attention, relevance maps або gate-conditioned paths.

Критерій D застосовується лише до selective SSM, зокрема Mamba, ViM та VMamba. Для лінійних часово-інваріантних SSM достатньо критеріїв A, S, C, T , але бажано додатково аналізувати частотну стабільність мод.

3. Чому сирі координати стану не є надійними ознаками

Для SSM існує проблема неідентифікованості стану. Якщо T є оборотною матрицею, то заміна

$$\tilde{x}(t) = Tx(t)$$

дає еквівалентну систему

$$\tilde{A} = TAT^{-1}, \quad \tilde{B} = TB, \quad \tilde{C} = CT^{-1}.$$

Вхідно-вихідна поведінка при цьому не змінюється. Отже, окрема координата $x_j(t)$ не має гарантованого семантичного змісту.

Через це в SSM безпечніше аналізувати не сирі координати стану, а інваріантні або краще визначені об'єкти: ядра K_k , власні моди, полюси, імпульсні характеристики, частотні відповіді, підпростори після вирівнювання між seed-моделями та gate-conditioned dependency patterns.

Для діагоналізованої SSM внесок окремої моди можна записати як

$$K_k^{(m)} = \alpha_m \lambda_m^k \beta_m, \quad K_k = \sum_m K_k^{(m)}.$$

Тут λ_m є власним значенням або дискретним полюсом, а α_m та β_m описують проєкції на вихідний і вхідний простори. Саме така форма є коректною для аналізу мод, оскільки вона не зводить інтерпретацію до довільно вибраної координати стану.

4. Порівняння методів інтерпретації

Методи інтерпретації, розроблені для CNN та ViT, не можна механічно переносити на SSM. Частина з них працює після адаптації, частина потребує суттєвої зміни об'єкта аналізу, а деякі методи мають сенс лише для лінійних часово-інваріантних SSM.

Метод	CNN / ViT	LTI SSM	Selective SSM	Необхідна модифікація	
Network Dissection	Природне застосування до карт активацій.	Можливе, але слід працювати з часовими або частотними масками.	Можливе для ViM та VMamba після обернення scan-order у 2D.	Піксельні маски треба замінити на часові, частотні, span-маски або inverse-scan spatial masks.	
Activation Maximization	Добре працює для візуалізації фільтрів і нейронів.	Менш надійне, бо синтетичний сигнал може створювати артефакти.	Обмежено корисне через контекстну залежність gating.	Потрібні регуляризатори гладкості, спектральні обмеження і перевірка на природних прикладах.	
Аналітичний аналіз ядра	Прямого аналога немає.	Найприродніший метод для S4, DSS, S4D, S5, LRU.	Малопридатний, бо параметри залежать від входу.	Будуються impulse response, pole map, transfer function, Bode magnitude.	
Exemplar Retrieval	Вибір природних прикладів з максимальною активацією.	Потрібно відбирати приклади за домінуванням мод або ядра.	Потрібно відбирати приклади за dependency maps або relevance maps.	Кластеризацію слід виконувати не в сирому просторі станів, а в просторі узгоджених ознак.	
Circuit Analysis	Аналіз локальних нейронних схем, фільтрів і зв'язків.	Аналіз композиції мод, полюсів і міжшарових ядер.	Аналіз gate-conditioned routes.	Потрібно переходити від статичних нейронів до динамічних маршрутів.	
Attribution LRP	/	Стандартні карти релевантності.	Можливе з обмеженістю, але слід враховувати рекурентну динаміку.	Особливо важливе для Mamba-подібних моделей.	Потрібні SSM-специфічні або induced-attention підходи.
Linear Probes	Простий і сильний базовий метод.	Добре працює для pooled states, modes або kernel features.	Добре працює, якщо probe враховує контекстні залежності.	Бажано використовувати регуляризацію, щоб уникнути зміщення ознак.	
Контроль порядку сканування	Зазвичай не потрібний.	Не застосовується до звичайних 1D SSM.	Обов'язковий для ViM та VMamba.	Ознака має перевірятися при різних scan routes.	

5. Структурне порівняння CNN, ViT, LTI SSM та selective SSM

Структурне порівняння потрібне для того, щоб показати, на якому рівні кожна архітектура природно формує інтерпретовані ознаки. У CNN такими одиницями часто є просторові фільтри, у ViT — token-to-token взаємодії, у LTI SSM — моди та ядра, а в selective SSM — динамічні маршрути, що залежать від вхідного сигналу.

Вимір порівняння	CNN	ViT	LTI SSM	Selective SSM
Локальність ознак	Просторово локальна, receptive field зростає з глибиною.	Глобальна через self-attention.	Історія інтегрується через ядро.	Історія інтегрується вибірково залежно від вхідного сигналу.
Базис ознак	Фільтри згортки.	Key-query-value взаємодії.	Моди, полюси, ядра, власні значення.	Вхідно-залежні маршрути та gating patterns.
Ідентифікованість стану	Відносно висока: фільтр має стабільну просторову роль.	Часткова: attention heads можуть мати ролі, але вони не завжди сталі.	Низька для сирих координат, вища для мод і ядер.	Низька для каналів, бо семантика залежить від контексту.
Частотний характер	Збалансований, залежить від даних і архітектури.	Може залежати від позиційного кодування і навчання.	Часто схильний до низькочастотних і довготривалих залежностей.	Адаптивний, визначається selective gates.
Семантика глибини	Перехід від країв і текстур до частин та об'єктів.	Менш жорстка ієрархія, роль шару залежить від архітектури.	Глибина не обов'язково відповідає просторовій ієрархії.	Глибина радше відображає складність маршрутизації інформації.
Найкращий рівень аналізу	Середні шари та карти активацій.	Attention heads, token embeddings, MLP features.	Kernel modes, pole-residue pairs, impulse responses.	Dependency motifs, gate-conditioned paths, induced attention.

6. Порівняння обмежень

Обмеження SSM-UFE мають переважно архітектурну природу. Вони не зводяться лише до нестачі інструментів інтерпретації, оскільки впливають із самої будови SSM: латентний стан не є однозначно ідентифікованим, частотна поведінка часто зміщена до довготривалих залежностей, а selective SSM змінюють свої маршрути залежно від входу.

Обмеження	Кого стосується	Серйозність для CNN / ViT	Серйозність для SSM	Коректна стратегія
Неідентифікованість стану	Усі SSM.	Низька.	Висока.	Не інтерпретувати сирих координат стану; аналізувати ядра, моди, полюси та вирівняні підпростори.

Обмеження	Кого стосується	Серйозність для CNN / ViT	Серйозність для SSM	Коректна стратегія
Низькочастотний зсув	Насамперед LTI SSM.	Низька або середня.	Середня або висока.	Додавати частотні ablation-тести і перевіряти високочастотні ознаки.
Контекстна залежність семантики	Selective SSM.	Середня для attention-моделей.	Висока.	Формулювати універсальність не на рівні каналу, а на рівні dependency motif.
Відсутність просторової ієрархії	Усі SSM.	Низька.	Середня.	Вибирати шари через kernel analysis, а не через CNN-евристику “чим глибше, тим семантичніше”.
Артефакти порядку сканування	ViM та VMamba.	Низька.	Висока.	Перевіряти різні scan routes і повертати ознаки у 2D-простір.
Масштабування навчання ознак	Великі SSM.	Середня.	Середня або висока.	Порівнювати кілька ширин моделі, seed-моделей і параметризацій.

7. Рекомендований протокол порівняльного експерименту

Для коректного порівняння CNN, ViT, LTI SSM та selective SSM потрібно оцінювати не лише якість на основній задачі, а й стабільність, інтерпретованість, каузальну значущість і переносимість знайдених ознак. Тому експериментальний протокол має включати кілька типів даних і кілька незалежних метрик.

Напрям	Моделі	Дані	Ознаки	Метрики
Зорові ознаки	CNN, ViT, ViM, VMamba.	ImageNet, Broden, COCO, ADE20K.	Краї, текстури, частини об'єктів, scan-direction motifs.	IoU, deletion AUC, cross-seed matching, transfer accuracy.
Довгі послідовності	S4, S5, DSS, LRU, Mamba, Transformer.	Long Range Arena, Pathfinder, Path-X.	Довготривалі залежності, лічильники, дужкові структури, path continuity.	Probe accuracy, ablation drop, length extrapolation.
Аудіо та часові ряди	S4D, DSS, S5, LRU, Mamba.	Speech Commands, часові ряди.	Onsets, pitch bands, keyword spans, spectral modes.	Span-IoU, spectral selectivity, perturbation AUC.

Напрям	Моделі	Дані	Ознаки	Метрики
Перенесення ознак	Будь-які заможені SSM, CNN або ViT.	Малі downstream-задачі.	Канали, моди, pooled states, dependency fs.	Linear accuracy, sample efficiency, transfer gap.

8. Узагальнена порівняльна оцінка

Узагальнена оцінка показує, що різні архітектури мають різний природний рівень інтерпретації. Для CNN таким рівнем є карти активацій і згорткові фільтри, для ViT — token-представлення та механізми уваги, для лінійних SSM — ядра, моди й полюси, а для selective SSM — вхідно-залежні маршрути передавання інформації.

Архітектура	Сильна сторона для UFE	Слабка сторона для UFE	Найбільш коректний об'єкт аналізу
CNN	Стабільні локальні фільтри і природна просторова ієрархія.	Менш придатні для дуже довгих залежностей.	Карти активацій, фільтри, середні шари.
ViT	Глобальні token-to-token взаємодії.	Attention не завжди є повним поясненням причинності.	Attention heads, token embeddings, attribution maps.
LTI SSM	Аналітично доступні ядра, полюси, моди і частотні характеристики.	Сирі координати стану неідентифіковані.	Impulse response, transfer function, pole-residue pairs.
Selective SSM	Вхідно-залежне маршрутизування інформації і лінійна складність за довжиною послідовності.	Семантика каналів змінюється від контексту до контексту.	Gate-conditioned dependency motifs, induced attention, relevance maps.
Vision SSM	Поєднання глобального контексту з ефективним скануванням зображення.	Можливі артефакти порядку сканування.	Inverse-scan spatial maps і route-consistent features.

Висновки

Універсальні ознаки в SSM не слід ототожнювати із сирими координатами латентного стану. На відміну від CNN, де окремий фільтр часто можна трактувати як відносно стабільний просторовий детектор, у SSM стан визначений з точністю до зміни базису. Тому для лінійних SSM найбільш надійними об'єктами аналізу є ядра, власні моди, імпульсні характеристики, полюси та частотні відповіді.

Для selective SSM, зокрема Mamba-подібних моделей, універсальність доцільно формулювати не як сталість одного каналу, а як повторюваність функціонального маршруту: gate-conditioned

dependency motif, induced attention pattern або relevance map. Такий підхід є обережнішим, але науково коректнішим, оскільки враховує вхідно-залежну природу selective state space dynamics.

Порівняння з CNN та ViT показує, що частина класичних методів інтерпретації переноситься на SSM лише після модифікації. Network Dissection, exemplar retrieval, linear probes та attribution-методи можуть бути корисними, але потребують адаптації до часових, частотних або scan-inverted просторових масок. Натомість аналіз імпульсних характеристик, полюсів і частотних відповідей є специфічною перевагою LTI SSM і не має прямого аналога у класичних CNN або ViT.

Отже, найбільш обґрунтованим є не твердження про абсолютну універсальність ознак у всіх архітектурах, а твердження про архітектурно-залежні універсальні функціональні мотиви, які стабільно виникають у межах певного сімейства SSM, узгоджуються з інтерпретованим поняттям, мають каузальний вплив на результат моделі і зберігають корисність при перенесенні на інші задачі.